

Togo AI Summer School 2026

Recueil des travaux pratiques



RÉPUBLIQUE TOGOLAISE

Ministère de l'Économie Numérique
et de la Transformation Digitale

#Data Lab

SOMMAIRE

1. Présentation générale et modalités	3
1.1 Cadre de l'événement	3
1.2 Vue d'ensemble des travaux pratiques	3
1.3 Modalités de soumission	4
1.4 Attendus communs à tous les sujets	4
2. TP 1 (filière F1) : « Planète CO ₂ »	5
2.1 Contexte et problématique	5
2.2 Objectifs d'apprentissage	5
2.3 Données et outils	5
2.4 Travail demandé (déroulé indicatif)	6
Partie 1 : Préparation et jointure · 45 min	6
Partie 2 : Indicateurs et analyse · 1 h	6
Partie 3 : Cartes et visualisations · 45 min	6
Partie 4 : Dashboard · 1 h à 1 h 30	6
Partie 5 : Interprétation et éthique · 30 min (écrit)	6
2.5 Résultat attendu et livrables	7
2.6 Grille d'évaluation (sur 100)	7
2.7 Questions à traiter	7
2.8 Bonus possible	8
3. TP 2 (filière F1) : Segmentation clients RFM	9
3.1 Contexte et problématique	9
3.2 Objectifs d'apprentissage	9
3.3 Données	9
3.4 Travail demandé (déroulé indicatif)	10
3.5 Résultat attendu et livrables	10
3.6 Grille d'évaluation (sur 100)	11
3.7 Questions à traiter dans le rapport	11
3.8 Bonus possible (+ 1 h 30)	11
4. TP 3 (filière F3) : Data Engineering & MLOps	12
	2

4.1 Contexte	12
4.2 Objectifs pédagogiques	12
4.3 Données fournies	12
4.4 Mission	13
4.5 Partie 1 : Architecture et modélisation	13
4.6 Partie 2 : Ingestion, qualité et transformation	13
4.7 Partie 3 : Orchestration avec Apache Airflow	14
4.8 Partie 4 : API	14
4.9 Partie 5 : Docker	14
4.10 Partie 6 : Passage à l'échelle et MLOps	14
4.11 Livrables attendus	15
4.12 Présentation du vendredi	15
4.13 Barème d'évaluation	16
4.14 Bonus	16
5. TP 4 (filière F4) : Géo-intelligence, SIG & Télédétection	17
5.1 Contexte et problématique	17
5.2 Objectifs	17
5.3 Organisation des sujets	17
5.4 Données	18
5.5 Étape 1 : Exploration des images satellitaires	18
5.6 Étape 2 : Calcul d'indices spectraux	18
5.7 Étape 3 : Classification du territoire	19
5.8 Étape 4 : Détection des changements	19
5.9 Étape 5 : Analyse temporelle	19
5.10 Étape 6 : Identification des hotspots	19
5.11 Étape 7 : Analyse spatiale avancée	20
5.12 Étape 8 : PostGIS	20
5.13 Étape 9 : Comparaison des zones	20
5.14 Cartographie thématique et webmapping	20
5.15 Livrables	21
5.16 Présentation	21
6. Synthèse comparative des quatre travaux pratiques	22
6.1 Données, outils et livrables	22

6.2 Points d'attention communs 22

Direction émettrice	TOGO AI LAB, Ministère de l'Économie Numérique et de la Transformation Digitale
Objet	Énoncés des travaux pratiques du Togo AI Summer School 2026 (TAISS 2026)
Événement	TAISS 2026, Lomé, du 24 au 29 août 2026
Filières concernées	F2 (Data Analyst), F1 (Data Scientist), F3 (Data Engineering & MLOps), F4 (Géo-intelligence, SIG & Télédétection)
Public	Participants de la Summer School, en équipe ou en binôme
Nombre de sujets	4 travaux pratiques
Dépôt du projet	https://ada.gouv.tg/DataLab/taiss2026.git
Version	1.0

1. Présentation générale et modalités

1.1 Cadre de l'événement

Le présent document rassemble en un support unique l'ensemble des énoncés de travaux pratiques (TP) proposés aux participants du Togo AI Summer School 2026 (TAISS 2026), organisé à Lomé du 24 au 29 août 2026.

Chaque énoncé constitue un projet à réaliser en équipe pendant la session et à restituer en fin de semaine. Les sujets couvrent trois filières complémentaires : la Data Analyst (Filière F2), la Data Science (filière F1), le Data Engineering & MLOps (filière F3) et la Géo-intelligence, SIG & Télédétection (filière F4).

Tous les sujets s'appuient sur des jeux de données réels et ouverts, et sont volontairement calibrés pour être menés à terme dans le temps imparti tout en mobilisant l'essentiel des concepts abordés durant la semaine.

1.2 Vue d'ensemble des travaux pratiques

Réf.	Filière	Intitulé	Durée	Modalité
TP 1	F2 : Data Analyst	« Planète CO ₂ » : industrialisation et émissions de gaz à effet de serre	Environ 4 h	Équipe
TP 2	F1 : Data Science	Segmentation clients RFM : « Comprendre ses clients pour mieux les servir »	Environ 4 h	Équipe
TP 3	F3 : Data Engineering & MLOps	Challenge : Retail Data Pipeline	Environ 4 h	Équipe
TP 4	F4 : Géo-intelligence, SIG & Télédétection	Analyse spatio-temporelle de la déforestation en Afrique	Environ 4 h	Équipe

1.3 Modalités de soumission

Les intervenants et les équipes déposent leurs supports et productions selon les modalités communiquées par l'équipe Communication :

- Formulaire de soumission (incluant le lien Nextcloud de dépôt) : <https://ee.form.gouv.tg/x/OWVAHnpV>
- Dépôt du projet TAISS 2026 de l'équipe DataLab sur Ada : <https://ada.gouv.tg/DataLab/taiss2026.git>
- Toute présentation comportant du code doit être accompagnée du lien vers le dépôt correspondant, renseigné dans le formulaire.
- Un intervenant mobilisé sur plusieurs créneaux renseigne l'ensemble de ses créneaux dans un même formulaire.

Date limite de soumission des supports : mercredi 19 août 2026.

1.4 Attendus communs à tous les sujets

1. Un dépôt de code (ou notebook) documenté et exécutable, accompagné d'un README décrivant la méthode et la procédure d'exécution.
2. Les livrables spécifiques listés dans chaque énoncé (dashboard, cartes, API, rapport, etc.).
3. Une restitution orale en fin de session, dont le format est précisé par sujet.

4. Une discussion critique des limites méthodologiques et des enjeux éthiques du travail réalisé.

2. TP 1 (filière F2) : « Planète CO₂ »

Industrialisation et émissions de gaz à effet de serre : réalisation d'un dashboard de visualisation et d'analyse. Durée : environ 4 h · par équipe · données réelles (OWID + Banque mondiale).

2.1 Contexte et problématique

Depuis deux siècles, l'industrialisation a transformé l'économie mondiale et fait exploser les émissions de gaz à effet de serre (GES). Mais les responsabilités sont très inégales : les pays industrialisés ont accumulé l'essentiel des émissions historiques, tandis que les pays en développement, dont l'Afrique, n'en émettent que très peu aujourd'hui tout en subissant les impacts climatiques.

Mission : construire un dashboard qui rend visible cette réalité : quels pays émettent le plus (aujourd'hui, par habitant, et cumulé depuis 1850), comment l'industrialisation s'y relie, et quel est l'impact par région du monde. Le dashboard doit permettre de comparer les pays industrialisés, émergents et africains.

2.2 Objectifs d'apprentissage

1. Préparer et joindre de gros jeux de données réels (CO₂ + indicateurs d'industrialisation) avec harmonisation des codes pays.
2. Construire des indicateurs pertinents : totaux vs par habitant vs cumulés historiques (trois histoires différentes).
3. Analyser le lien industrialisation / émissions avec le cadre de l'identité de Kaya (décomposition).
4. Visualiser : cartes choroplèthes, séries temporelles (log), nuages de points, et assembler un dashboard interactif.
5. Interpréter et discuter la justice climatique (responsabilité historique vs actuelle) et les limites des données.

2.3 Données et outils

- CO₂ et GES (OWID) : CSV direct, sans inscription, ~270 pays × années 1850-2023 (certaines séries depuis 1750) :
<https://raw.githubusercontent.com/owid/co2-data/master/owid-co2-data.csv>
- Colonnes clés : country, iso_code (alpha-3), year, population, gdp, co2, co2_per_capita, cumulative_co2, share_global_co2, coal_co2, oil_co2, gas_co2, cement_co2, methane, nitrous_oxide, gdp_per_capita...

- Industrialisation (Banque mondiale) : valeur ajoutée de l'industrie (% du PIB) et PIB par habitant :
<https://api.worldbank.org/v2/country/all/indicator/NV.IND.TOTL.ZS?format=json>
- Outils : Python + Streamlit + Plotly (recommandé : gratuit, reproductible, hors-ligne) ou Power BI Desktop (gratuit mais Windows, moins reproductible). Les cartes Plotly utilisent directement iso_code.

2.4 Travail demandé (déroulé indicatif)

Partie 1 : Préparation et jointure

1. Charger le CSV OWID et l'API Banque mondiale ; harmoniser les codes pays.
2. Gérer les cas difficiles : pays dissous (URSS, Allemagne), agrégats (« World », régions), valeurs manquantes.

Partie 2 : Indicateurs et analyse

1. Top 10 des émetteurs selon trois angles : émissions totales actuelles, par habitant, cumulées depuis 1850 : que révèlent trois classements différents ?
2. Parts régionales (Afrique, Asie, Europe, Amériques, Océanie) au fil du temps : qui dominait hier, qui domine aujourd'hui ?
3. Identité de Kaya décomposée pour trois pays contrastés (ex. Chine, États-Unis, Togo/Nigéria) : la croissance vient-elle de la population, du PIB par habitant, de l'intensité énergétique ?
4. Découplage : des pays croissent-ils économiquement (PIB en hausse) tout en émettant moins (CO₂ en baisse) ?

Partie 3 : Cartes et visualisations

1. Choroplèthe monde : co2_per_capita, cumulative_co2, part de l'industrie (% du PIB).
2. Séries temporelles par pays/région (échelle log vs linéaire, à justifier).
3. Nuage de points PIB par habitant vs CO₂ par habitant (une année, tous pays).

Partie 4 : Dashboard

Assembler un dashboard interactif : carte mondiale, évolution temporelle, comparaison de régions et de pays, indicateurs clés. Interactivité attendue : sélecteur d'année, de pays et de région, bascule entre indicateurs.

Partie 5 : Interprétation et éthique

1. Responsabilité historique vs actuelle : qui « doit » réduire ?
2. Limites : émissions territoriales vs émissions liées à la consommation (biens fabriqués ailleurs), qualité des données historiques.

2.5 Résultat attendu et livrables

1. Un dashboard fonctionnel (carte, évolution, comparaison de régions, indicateurs clés).
2. Des analyses chiffrées documentées.
3. Un rapport de 2 à 3 pages : méthode, choix d'indicateurs, interprétation, limites, réponses aux questions.

Livrables : notebook d'analyse (parties 1 à 3), dashboard (script Streamlit .py ou fichier Power BI .pbix) et rapport de 2 à 3 pages.

2.6 Grille d'évaluation (sur 100)

Rubrique	Points
Préparation et jointure des données (P1)	20
Indicateurs et analyse (P2)	25
Cartes et visualisations (P3)	20
Dashboard interactif (P4)	20
Interprétation et éthique (P5)	10
Qualité du rapport	5
Total	100

2.7 Questions à traiter

1. Totaux, par habitant, cumulés : lequel reflète la « responsabilité » ? Pourquoi trois classements différents ?
2. Décomposez la Chine, les États-Unis et un pays africain avec l'identité de Kaya : quelle composante domine ?
3. Le découplage (PIB en hausse, CO₂ en baisse) observé en Europe est-il réel ou un artefact (délocalisation) ?
4. Les émissions territoriales ignorent le commerce : que change l'approche « consommation » (ajustée aux échanges) ?
5. Pourquoi les échelles logarithmiques sont-elles indispensables ici (hétérogénéité des pays) ?
6. Justice climatique : quel poids pour l'Afrique dont la part des émissions cumulées est minime ?

2.8 Bonus possible

- Pr vision des  missions d'une r gion (ARIMA / Prophet).
- Ajout des autres GES (m thane, N₂O) d j  pr sents dans le CSV, et du CO₂e.

3. TP 2 (filière F1) : Segmentation clients RFM

« Comprendre ses clients pour mieux les servir ». Durée : environ 4 h · données réelles (UCI Online Retail II).

3.1 Contexte et problématique

Un e-commerce de cadeaux, basé au Royaume-Uni et opérant principalement en gros, cumule plus d'un million de transactions sur deux ans. La direction veut personnaliser ses campagnes marketing (courriels, promotions, relances) et réduire l'attrition, mais elle ne connaît pas ses clients. Faut-il choyer les meilleurs acheteurs, relancer ceux qui s'éloignent, réveiller ceux qui dorment ? Sans typologie, toute action marketing tire à l'aveugle.

Mission : construire une segmentation clients à partir du comportement d'achat (méthode RFM : Récence, Fréquence, Montant), identifier et nommer des segments actionnables, et formuler des recommandations marketing par segment. La méthode est directement transposable à un e-commerce ouest-africain ou à une plateforme de paiement mobile.

3.2 Objectifs d'apprentissage

1. Nettoyer un jeu de transactions réelles et bruitées (annulations, retours, identifiants manquants, valeurs aberrantes).
2. Construire les features RFM par client et les transformer correctement (distributions fortement asymétriques).
3. Justifier le choix du nombre de segments k (silhouette, coude, stabilité, cohérence métier).
4. Interpréter et nommer les segments, les caractériser (taille, chiffre d'affaires, profil, produits, pays).
5. Discuter des limites du clustering et des enjeux éthiques de la personnalisation.

3.3 Données

Source réelle : UCI Online Retail II. Lien ZIP :

<https://archive.ics.uci.edu/static/public/502/online+retail+ii.zip> (ou `fetch_ucirepo(id=502)`). Le fichier Excel contient deux feuilles à concaténer : « Year 2009-2010 » et « Year 2010-2011 ».

Colonne	Description
InvoiceNo	N° de facture
StockCode	Code produit (5 chiffres)
Description	Nom du produit

Colonne	Description
Quantity	Quantité
InvoiceDate	Date et heure
UnitPrice	Prix unitaire en livres (£)
CustomerID	Identifiant client
Country	Pays du client (~91 % UK, ~37 pays)

3.4 Travail demandé (déroulé indicatif)

- Partie 1 : Nettoyage des transactions
- Partie 2 : Construction et transformation des features RFM
- Partie 3 : Clustering et choix de k
- Partie 4 : Caractérisation et recommandations
- Partie 5 : Discussion critique et éthique

3.5 Résultat attendu et livrables

À la fin, vous devez produire un système de segmentation exploitable :

1. Un jeu de clients nettoyé avec les features RFM (et transformations documentées).
2. Un choix de k argumenté (graphique silhouette / coude et justification écrite).
3. Des segments nommés et caractérisés dans un tableau de synthèse.
4. Des recommandations marketing par segment (1 à 2 lignes chacune).
5. Un rapport de 2 à 3 pages documentant méthode, choix et limites, et répondant aux questions.

Segment	Effectif	% CA	Récence moy.	Fréquence moy.	Montant moy.	Top pays / produits
Champions	...	...	...	...	...	...
À risque	...	...	...	...	...	...
...	...	...	...	...	...	...

Livrables : notebook complété (parties 1 à 4), rapport de 2 à 3 pages et tableau de synthèse ci-dessus.

3.6 Grille d'évaluation (sur 100)

Rubrique	Points
Nettoyage des transactions (P1)	20
Features RFM et transformations (P2)	20
Choix de k et clustering (P3)	25
Caractérisation et recommandations (P4)	20
Discussion critique et éthique (P5)	10
Qualité du rapport et reproductibilité	5
Total	100

3.7 Questions à traiter dans le rapport

1. Annulations et retours : leur traitement change-t-il significativement les segments ? Comment le vérifier ?
2. Pourquoi ne pas appliquer K-means sur les RFM bruts ? Que gagne-t-on exactement avec log + standardisation ?
3. Fréquence et Montant sont souvent corrélés : comment traiter cette redondance ?
4. La silhouette ne suffit pas à choisir k : pourquoi ? (stabilité, taille, cohérence métier)
5. Sans vérité terrain, comment défendre la qualité des segments ?
6. Personnaliser les offres peut mener à de la tarification différenciée : quels garde-fous ?

3.8 Bonus possible (+ 1 h)

Ajouter une couche d'interrogation en langage naturel des résultats : base vectorielle et assistant répondant aux questions du marketing (« combien de Champions ? », « décris les clients endormis ») en citant les vrais chiffres.

4. TP 3 (filière F3) : Data Engineering & MLOps

Challenge Retail Data Pipeline : construction d'une mini-chaîne Data Engineering fonctionnelle et proposition d'une architecture cible de production.

4.1 Contexte

Une entreprise disposant de plusieurs points de vente souhaite centraliser quotidiennement ses transactions afin de faciliter leur analyse et le suivi de ses activités. Chaque magasin produit des fichiers contenant les transactions réalisées ; l'entreprise dispose également de données de référence sur les produits, les clients et les magasins.

L'objectif du challenge est de construire une mini-chaîne Data Engineering fonctionnelle, puis de proposer son évolution vers une architecture de production intégrant les concepts de MLOps et de passage à l'échelle. Le projet est volontairement limité afin de pouvoir être réalisé en quelques heures, tout en mobilisant les principaux concepts abordés durant la semaine.

4.2 Objectifs pédagogiques

À l'issue du TP, les participants devront être capables de :

- proposer une architecture de données adaptée à un besoin métier ;
- concevoir un modèle dimensionnel simple ;
- ingérer, nettoyer et transformer des données ;
- orchestrer un pipeline avec Apache Airflow ;
- charger les données dans un Data Warehouse PostgreSQL ;
- exposer des indicateurs à travers une API ;
- conteneuriser un service avec Docker ;
- expliquer comment NiFi, CI/CD, monitoring et Kubernetes pourraient être intégrés dans une architecture de production.

4.3 Données fournies

Les participants disposent d'un jeu de données organisé de la manière suivante :

```
data/
├── stores.csv
├── products.csv
├── customers.csv
├── transactions/
│   ├── sales_2026_08_01.csv
│   ├── sales_2026_08_02.csv
│   └── sales_2026_08_03.csv
```

Certaines données peuvent volontairement contenir des anomalies : doublons, valeurs manquantes, formats de dates incorrects, références de produits inconnues, données incohérentes.

4.4 Mission

Votre équipe doit concevoir et implémenter une mini-plateforme permettant de transformer les fichiers de transactions en données exploitables. La chaîne minimale attendue est la suivante :


```
Fichiers CSV → Ingestion → Validation / Nettoyage → Transformation  
→ PostgreSQL (Data Warehouse) → API → Docker
```

Apache Airflow sera utilisé pour orchestrer les différentes étapes du pipeline.

4.5 Partie 1 : Architecture et modélisation

Architecture : proposez un schéma représentant les différents composants de votre solution et les flux de données entre ces composants. Vous devez être capables de justifier vos principaux choix techniques.

Modélisation dimensionnelle : à partir des données fournies, concevez un modèle dimensionnel permettant d'analyser les ventes. Un modèle possible pourrait suivre le principe suivant :



La conception exacte reste à la charge de chaque équipe. Vous devrez notamment identifier la table de faits, les dimensions, les clés et les principales mesures nécessaires à l'analyse. Implémentez ensuite le modèle retenu dans PostgreSQL.

4.6 Partie 2 : Ingestion, qualité et transformation

Construisez un traitement permettant de récupérer les fichiers de transactions et de préparer les données avant leur chargement dans le Data Warehouse. Le traitement devra au minimum :

1. lire automatiquement les fichiers de transactions ;
2. détecter ou supprimer les doublons ;
3. traiter les valeurs manquantes selon une stratégie pertinente ;
4. normaliser les dates ;
5. identifier ou rejeter les transactions faisant référence à des produits inexistants ;
6. calculer le montant d'une transaction ($\text{total_amount} = \text{quantity} \times \text{unit_price}$).

Contrainte importante : le pipeline doit pouvoir traiter un nouveau fichier ajouté dans le dossier transactions/ sans nécessiter de modification du code.

4.7 Partie 3 : Orchestration avec Apache Airflow

Construisez un DAG Airflow permettant d'orchestrer le traitement. Une organisation possible est :

```
ingest_data → validate_data → transform_data → load_warehouse
```

Chaque équipe est libre d'adapter cette organisation si elle justifie son choix. À la fin de l'exécution du DAG, les nouvelles transactions valides doivent être disponibles dans le Data Warehouse.

4.8 Partie 4 : API

Développez une petite API permettant d'accéder à quelques indicateurs calculés à partir du Data Warehouse. Vous pouvez utiliser FastAPI ou une technologie équivalente. L'API devra exposer au minimum trois indicateurs métier, par exemple :

```
GET /sales/summary
GET /sales/by-store
GET /sales/by-product
```

Une réponse de synthèse pourrait par exemple avoir la structure suivante :

```
{
  "total_sales": 18450000,
  "transactions": 1243,
  "best_selling_product": "Produit A"
}
```

Les groupes sont libres de proposer d'autres indicateurs pertinents.

4.9 Partie 5 : Docker


Conteneurisez l'API afin qu'elle puisse être exécutée de manière reproductible. L'objectif n'est pas nécessairement de conteneuriser l'intégralité de l'infrastructure ; le minimum attendu est un conteneur Docker exécutant l'API et communiquant avec PostgreSQL. Le conteneur doit pouvoir démarrer le service API et permettre l'accès aux endpoints développés précédemment.

4.10 Partie 6 : Passage à l'échelle et MLOps

Considérez maintenant le scénario suivant : l'entreprise passe de quelques magasins à plusieurs centaines de points de vente et doit traiter plusieurs millions de transactions. La plateforme devient critique et doit être disponible, observable et facilement déployable.

Vous ne devez pas nécessairement implémenter tous les composants supplémentaires, mais votre équipe doit proposer une architecture cible montrant comment les concepts vus durant la semaine pourraient être utilisés. Votre proposition devra notamment considérer :

- Apache NiFi pour l'ingestion ou la gestion des flux ;
- CI/CD pour automatiser les tests et les déploiements ;
- Kubernetes pour le déploiement et le passage à l'échelle ;
- un système de monitoring ;
- Prometheus / Grafana ou des solutions équivalentes ;
- la gestion de plusieurs instances de l'API.



Il ne suffit pas de placer les technologies sur le diagramme : vous devez être capables d'expliquer le rôle de chaque composant et la raison de son utilisation.

4.11 Livrables attendus

1. Un dépôt Git contenant le code du projet et un README expliquant comment l'exécuter.
2. Un schéma d'architecture de la solution développée.
3. Le modèle dimensionnel du Data Warehouse.
4. Le DAG Airflow et les scripts nécessaires au traitement des données.
5. L'API fonctionnelle et son Dockerfile.
6. Une architecture cible montrant comment la solution pourrait évoluer vers une plateforme de production utilisant les concepts de MLOps, monitoring et Kubernetes.

4.12 Présentation du vendredi

Chaque groupe disposera de 5 minutes de présentation et de 2 minutes de démonstration. La présentation devra montrer de manière synthétique : le problème traité, l'architecture retenue, le modèle dimensionnel, le fonctionnement du pipeline, les choix techniques réalisés et l'architecture proposée pour le passage à l'échelle.

La démonstration minimale devra montrer l'enchaînement suivant : ajout d'un fichier, puis exécution du pipeline, puis chargement dans PostgreSQL, puis interrogation de l'API.

4.13 Barème d'évaluation

Critère	Poids
Architecture et justification des choix	20 %
Modélisation dimensionnelle	20 %
Pipeline Airflow fonctionnel	25 %
Qualité et transformation des données	15 %
API et Docker	10 %
Proposition MLOps / Kubernetes / monitoring	10 %
Total	100 %

4.14 Bonus

Les groupes qui terminent rapidement peuvent aller plus loin en implémentant un ou plusieurs éléments supplémentaires : ingestion avec Apache NiFi, dashboard Grafana, métriques Prometheus, pipeline CI/CD, déploiement Kubernetes, tests automatisés, dashboard analytique, ajout d'un modèle de Machine Learning simple, ajout d'un agent IA capable d'interroger certains indicateurs de la plateforme.

Ces éléments sont facultatifs et ne doivent pas empêcher la réalisation du pipeline principal.

5. TP 4 (filière F4) : Géo-intelligence, SIG & Télédétection

| Analyse spatio-temporelle de la déforestation en Afrique à partir d'images satellitaires.

5.1 Contexte et problématique

Les forêts africaines jouent un rôle important dans la biodiversité, le stockage du carbone, la régulation du climat et les activités économiques des populations. Cependant, certaines régions connaissent une diminution importante de leur couvert forestier sous l'effet de l'expansion agricole, de l'urbanisation, de l'exploitation du bois, des incendies et d'autres transformations du territoire.

Les satellites d'observation de la Terre permettent aujourd'hui de suivre ces transformations sur plusieurs années. Votre équipe devra exploiter des données satellitaires ouvertes et des outils SIG afin d'analyser l'évolution du couvert forestier d'une zone africaine.

Problématique : comment le couvert forestier a-t-il évolué dans la zone étudiée au cours des dernières années, où se concentrent les pertes et quels facteurs spatiaux peuvent être associés à ces transformations ?

5.2 Objectifs

Votre équipe devra :

- récupérer des images satellitaires ouvertes ;
- préparer et explorer les données dans QGIS ;
- utiliser Google Earth Engine pour effectuer une analyse temporelle ;
- identifier les surfaces forestières et mesurer leur évolution ;
- détecter les zones de perte de couvert forestier et les analyser spatialement ;
- utiliser une méthode simple de Machine Learning géospatial ;
- stocker les résultats dans PostGIS ;
- produire une cartographie thématique ;
- publier les résultats dans un WebGIS.

5.3 Organisation des sujets

Chaque équipe travaillera sur une zone forestière au choix, en limitant son territoire à une zone raisonnable : région, province, aire protégée ou autre territoire clairement défini.

Sujet	Zone d'étude
A : Bassin du Congo	Une zone de la République démocratique du Congo ou d'un pays voisin
B : Afrique de l'Ouest	Une zone forestière du Togo, du Ghana, de la Côte d'Ivoire ou du Bénin
C : Afrique centrale	Une zone du Cameroun ou du Gabon
D : Afrique de l'Est	Une zone forestière du Kenya, de l'Ouganda, de la Tanzanie ou de Madagascar

5.4 Données

Les équipes devront privilégier des données ouvertes.

Imagerie satellitaire : utiliser principalement Sentinel-2 ou Landsat 8/9. Les données peuvent être obtenues et traitées via Google Earth Engine. Pour une analyse historique plus longue, les différentes générations Landsat peuvent également être utilisées.

Données complémentaires possibles : limites administratives, routes, villes et localités, aires protégées, cours d'eau, données d'occupation du sol. Les données OpenStreetMap peuvent notamment être utilisées pour certaines infrastructures.

5.5 Étape 1 : Exploration des images satellitaires

Sélectionnez au minimum trois périodes différentes (par exemple 2018, 2022 et 2026). Pour chaque période :

1. sélectionner des images de la même saison ;
2. limiter la couverture nuageuse ;
3. produire une image composite ;
4. découper l'image selon la zone d'étude.

Important : les images doivent être suffisamment comparables. Évitez par exemple de comparer une image en pleine saison sèche avec une image prise pendant la saison des pluies sans prendre cette différence en compte.

5.6 Étape 2 : Calcul d'indices spectraux

Calculer au minimum deux indices. Utiliser le NDVI pour analyser la végétation :

$$NDVI = (NIR - RED) / (NIR + RED)$$

Produire une carte NDVI pour chaque période. Choisissez ensuite un indice supplémentaire pertinent (NDMI, NBR, EVI ou autre indice justifié) et expliquez pourquoi cet indice est pertinent pour l'étude du couvert végétal.

5.7 Étape 3 : Classification du territoire

Construisez une classification simple permettant de distinguer au minimum : forêt, autre végétation, zone bâtie / sol nu, eau. Deux approches sont possibles.

Approche A, classification par règles : construire une classification à partir des indices spectraux et de seuils justifiés.

Approche B, apprentissage automatique : utiliser un algorithme de classification tel que Random Forest ou CART. Vous devrez expliquer les variables utilisées, les données d'entraînement, le modèle choisi et la méthode d'évaluation.

5.8 Étape 4 : Détection des changements

Comparez les cartes obtenues entre les différentes périodes. Votre objectif principal est d'identifier les pixels ou zones passant de FORÊT à NON-FORÊT, et de produire une couche représentant les zones de perte de couvert forestier.

Calculez ensuite : la superficie forestière initiale, la superficie forestière finale, la superficie forestière perdue, le pourcentage de perte et l'évolution annuelle approximative.

5.9 Étape 5 : Analyse temporelle

Construisez une série temporelle montrant l'évolution de la surface forestière.

Année	Surface forestière
2018	... km ²
2020	... km ²
2022	... km ²
2024	... km ²
2026	... km ²

Répondez notamment aux questions suivantes : la perte est-elle continue ? Certaines périodes présentent-elles une accélération ? Observez-vous éventuellement des zones de récupération de végétation ?

5.10 Étape 6 : Identification des hotspots

Toutes les pertes forestières ne sont pas réparties uniformément. Identifiez les zones où la disparition du couvert forestier est particulièrement concentrée et produisez une carte des hotspots de perte forestière. Vous pourrez utiliser une grille spatiale, une agrégation, une analyse de densité, des statistiques spatiales ou toute autre méthode justifiée.

5.11 Étape 7 : Analyse spatiale avancée

Vous devez maintenant essayer de comprendre la distribution spatiale de la déforestation. Analysez notamment la proximité entre les pertes forestières et les routes, les zones urbaines, les villages et localités, ainsi que les limites d'aires protégées.

Exemple de question : les zones de perte forestière sont-elles plus fréquentes à proximité des routes ?

Construisez plusieurs classes de distance (0-1 km, 1-5 km, 5-10 km, plus de 10 km) et comparez la quantité de forêt perdue dans ces différentes zones.

5.12 Étape 8 : PostGIS

Stockez les principaux résultats dans PostGIS. La base pourra contenir les tables `study_area`, `forest_cover`, `forest_loss`, `roads`, `protected_areas` et `hotspots`.

Effectuez au minimum trois requêtes spatiales, par exemple :

- Surface perdue par territoire : calculer la superficie forestière perdue par unité administrative.
- Déforestation et routes : identifier les hotspots situés à moins de 2 km d'une route.
- Aires protégées : calculer la surface forestière perdue à l'intérieur des aires protégées.

5.13 Étape 9 : Comparaison des zones

À la fin du projet, les résultats des différentes équipes pourront être réunis dans un tableau comparatif :

Zone	Forêt initiale	Forêt finale	Perte	Taux
Zone A	...	...	...	...
Zone B	...	...	...	...
Zone C	...	...	...	...
Zone D	...	...	...	...

Attention : les résultats concernent les zones étudiées et ne permettent pas nécessairement de conclure qu'un pays entier ou que l'ensemble de l'Afrique suit exactement la même tendance.

5.14 Cartographie thématique et webmapping

Produisez au minimum trois cartes : le couvert forestier initial (situation au début de la période), le couvert forestier récent (situation à la fin de la période) et les pertes forestières (localisation des zones où le couvert forestier a disparu). Une quatrième carte présentant les hotspots est recommandée.

Développez ensuite une carte Web interactive présentant les résultats. Elle devra permettre de sélectionner une période, d'afficher le couvert forestier, les pertes et les hotspots, d'activer ou désactiver les routes et aires protégées, et de cliquer sur une zone pour obtenir des informations :

Zone : Hotspot 17
Forêt perdue : 14,7 km²
Période : 2018-2026
Route la plus proche : 1,3 km
Aire protégée : Non

5.15 Livrables

1. Projet QGIS.
2. Script Google Earth Engine.
3. Script ou notebook de classification.
4. Scripts ou requêtes PostGIS.
5. Cartes thématiques.
6. WebGIS.
7. Résultats statistiques.
8. README expliquant la méthodologie.

5.16 Présentation

Durée recommandée : 10 minutes. La présentation devra couvrir :

1. Zone étudiée : où se trouve-t-elle et pourquoi l'avez-vous choisie ?
2. Données : quelles images satellitaires avez-vous utilisées ?
3. Méthodologie : comment avez-vous identifié la forêt ?
4. Évolution : quelle évolution observez-vous ?
5. Hotspots : où se trouvent les principales pertes ?
6. Analyse spatiale : existe-t-il une relation apparente avec les routes, villes ou aires protégées ?
7. Démonstration : présentez le WebGIS et la comparaison avant / après.

Votre présentation devra se terminer en répondant à cette question : que nous apprend l'observation satellitaire sur l'évolution du couvert forestier de votre zone d'étude, et quelles zones devraient faire l'objet d'une surveillance prioritaire ?

6. Synthèse comparative des quatre travaux pratiques

6.1 Données, outils et livrables

TP	Données principales	Outils attendus	Livrables clés
TP 1 : Planète CO ₂	OWID co2-data, API Banque mondiale	Python, Streamlit, Plotly (ou Power BI)	Notebook, dashboard, rapport 2-3 p.
TP 2 : Segmentation RFM	UCI Online Retail II	Python, scikit-learn	Notebook, tableau de segments, rapport 2-3 p.
TP 3 : Retail Data Pipeline	Fichiers CSV magasins / produits / clients	Airflow, PostgreSQL, FastAPI, Docker	Dépôt Git, DAG, API + Dockerfile, architecture cible
TP 4 : Déforestation	Sentinel-2, Landsat 8/9, OpenStreetMap	QGIS, Google Earth Engine, PostGIS, WebGIS	Projet QGIS, scripts, cartes, WebGIS, README

6.2 Points d'attention communs

- Reproductibilité : chaque production doit pouvoir être ré-exécutée à partir du dépôt et du README fournis.
- Justification des choix : seuils, hyperparamètres, nombre de segments, indicateurs et technologies doivent être argumentés, pas seulement appliqués.
- Limites méthodologiques : chaque équipe doit expliciter ce que ses résultats ne permettent pas de conclure.
- Éthique : justice climatique (TP 1), personnalisation et tarification différenciée (TP 2), usage des données (TP 3 et TP 4).