

Machine learning appliqué à l'agriculture

Comprendre la donnée géospatiale agricole, construire un modèle, et l'évaluer correctement.

COURS 2 H • TP GUIDÉ 30 MIN



Summer School IA

Gnouyaro Zissler Sogoyou • Togo AI Lab



La difficulté n'est presque jamais l'algorithme.

Six parties, une seule chaîne. Le temps indiqué est le temps prévu pour chacune.



Un quart du cours porte sur la compréhension de la donnée géospatiale et un tiers sur l'évaluation. Le choix de l'algorithme occupe cinq minutes : sur la plupart des projets agricoles, c'est l'étape la moins déterminante.

À RETENIR Le ruban en bas de chaque slide indique l'étape de la chaîne en cours de traitement.



Quatre différences avec un problème de machine learning classique

Elles expliquent la totalité des choix méthodologiques du cours.

I

L'objet à observer est vaste et peu accessible

On ne peut pas instrumenter chaque parcelle. L'observation passe par des capteurs distants — satellites, avions, drones — qui mesurent un rayonnement, pas une culture.

→ Il faudra apprendre à lire une donnée d'observation de la Terre.

II

L'objet change en permanence

Une parcelle n'a pas de signature fixe : elle change de semaine en semaine, et le calendrier se décale d'une année à l'autre selon la pluie.

→ Une image isolée ne suffit pas. Il faudra travailler sur des séries temporelles.

III

La vérité de terrain coûte cher

Savoir ce qui pousse réellement sur une parcelle suppose qu'un agent s'y rende. Le nombre de labels se compte en centaines ou en milliers, pas en millions.

→ Le volume d'images ne compensera jamais le manque de labels.

IV

Les observations voisines se ressemblent

Deux parcelles séparées de 200 mètres partagent le sol, le climat, le calendrier de pluie et souvent la variété semée.

→ Le protocole d'évaluation devra en tenir compte. C'est le point central du cours.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

Quatre familles de problèmes agricoles, quatre tâches de machine learning

La tâche découle de la décision visée, pas de la donnée disponible.

FAMILLE	QUESTION AGRICOLE	TÂCHE ML	SORTIE	DÉCISION ASSOCIÉE
CARTOGRAPHIER	Où sont les cultures, et lesquelles ?	Classification (par pixel ou par parcelle)	Une carte d'occupation du sol	Statistique agricole, ciblage d'un programme
DÉTECTER	Y a-t-il une anomalie sur cette parcelle ?	Classification d'image ou détection d'objet	Une alerte localisée	Traitement phytosanitaire, visite d'un agent
PRÉDIRE	Quel rendement à la récolte ?	Régression	Une valeur en t/ha	Planification, achat, assurance indicielle
SUIVRE	Où en est la saison par rapport à la normale ?	Comparaison de séries temporelles	Un écart à une référence	Alerte précoce, gestion de stocks
À RETENIR Une même donnée satellitaire alimente ces quatre familles. Ce qui change à chaque fois, c'est la sortie attendue et la métrique à surveiller.				

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION


PRÉDICTION

DÉCISION

Ce qu'un capteur d'observation de la Terre mesure réellement


Étape 1 sur 5 : le pixel et les bandes spectrales.

UNE IMAGE EST UNE GRILLE DE PIXELS



Chaque case couvre une surface au sol fixe.
Ici, chaque case représente 10 m × 10 m.

UN PIXEL EST UNE LISTE DE MESURES



Le capteur ne voit ni une plante ni une parcelle : il mesure la part de lumière renvoyée dans quelques longueurs d'onde.

POURQUOI CELA RENSEIGNE SUR LA VÉGÉTATION

La chlorophylle absorbe fortement le rouge.

La structure interne de la feuille réfléchit fortement le proche infrarouge.

Une végétation dense présente donc un contraste marqué entre ces deux bandes. Un sol nu, non.

C'est exactement ce que mesurera un indice de végétation, à la slide 8.

À RETENIR Le modèle ne recevra jamais « du maïs ». Il recevra des nombres qui décrivent la lumière renvoyée par une surface de 10 m de côté, à une date donnée.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

Trois résolutions à regarder avant de choisir une source de données

Étape 2 sur 5 : ce que chaque résolution permet et ce qu'elle interdit.

SPATIALE Taille au sol d'un pixel	Quelques dizaines de centimètres pour un drone, quelques mètres pour l'imagerie commerciale, une dizaine de mètres pour l'imagerie publique gratuite, plusieurs centaines de mètres pour les capteurs à large fauchée.	Si le pixel est plus grand que la parcelle, la mesure mélange plusieurs occupations du sol.
TEMPORELLE Délai entre deux passages sur le même point	De quelques jours pour les constellations publiques à plusieurs semaines pour les capteurs à haute résolution spatiale. Un drone passe quand on le décide, mais ne couvre qu'une exploitation.	Si la revisite est trop lente, le cycle de la culture n'est pas échantillonné et la phénologie est invisible.
SPECTRALE Nombre et largeur des bandes mesurées	Trois bandes pour une caméra ordinaire, une dizaine pour un capteur multispectral courant, plusieurs centaines pour un capteur hyperspectral.	Peu de bandes suffisent à distinguer végétation et sol. Distinguer deux cultures proches en demande davantage.


Deux physiques de mesure. Un capteur optique mesure la lumière solaire réfléchie : il est aveugle sous les nuages, donc pendant la saison des pluies, donc pendant la saison culturale en zone tropicale. Un capteur radar émet son propre signal et traverse la couverture nuageuse, mais mesure la rugosité et l'humidité plutôt que la couleur. En Afrique de l'Ouest, les deux se complètent.

PROBLÈME	DONNÉES	LABELS	FEATURES	MODÈLE	ÉVALUATION	PRÉDICTION	DÉCISION
----------	----------------	--------	----------	--------	------------	------------	----------

Quand le pixel est plus grand que la parcelle

Étape 3 sur 5 : la contrainte structurelle de l'agriculture familiale.


GRANDE EXPLOITATION



Un pixel = une seule culture

La parcelle contient 24 pixels entiers. La signature mesurée décrit une culture unique.

EXPLOITATION FAMILIALE (< 0,5 ha)



Un pixel = plusieurs choses à la fois

Aucune parcelle ne couvre un pixel entier. Le pixel encadré contient du sol nu, un arbre et deux cultures.

CE QUE MESURE ALORS LE CAPTEUR

	Sol nu	38 %
	Culture principale	31 %
	Arbre	19 %
	Culture associée	12 %

La valeur enregistrée est une moyenne pondérée de ces quatre surfaces. Elle ne correspond à aucune des quatre. C'est ce qu'on appelle un pixel mixte.

À RETENIR Vérifier la taille médiane des parcelles de la zone d'étude avant de choisir une source d'images. En dessous d'environ un demi-hectare, l'imagerie publique à 10 m atteint sa limite et il faut soit une résolution plus fine, soit un raisonnement à l'échelle de la parcelle et non du pixel.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION


PRÉDICTION

DÉCISION

D'une image isolée à une série temporelle

Étape 4 sur 5 : une culture ne se reconnaît pas sur une image, elle se reconnaît sur un cycle.

LA MÊME ZONE, OBSERVÉE À PLUSIEURS DATES



Juillet

Mai


Mars

Janvier

On suit un même pixel, image après image. Le carré rouge marque le pixel choisi.



CE QUE RACONTE LA SÉRIE DE CE PIXEL



À RETENIR Sur une image du mois de mars, les deux cultures se ressemblent. Sur la saison entière, elles se distinguent nettement : l'une culmine en avril, l'autre en mai. C'est le décalage du cycle qui porte l'information, pas la valeur d'une date.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

Des mesures brutes aux variables du modèle

Étape 5 sur 5 : réduire une série de plusieurs centaines de nombres à quelques variables interprétables.



POURQUOI CETTE RÉDUCTION EST NÉCESSAIRE

Avec quelques centaines de labels seulement, un modèle nourri de plusieurs centaines de variables brutes apprend le bruit de son échantillon. Passer par des descripteurs du cycle réduit le nombre de variables, les rend interprétables, et permet à un agronome de vérifier que le modèle utilise une information plausible. La variable « date du pic » se discute avec un agronome ; la variable « bande proche infrarouge au 12 mars » ne se discute pas.

À RETENIR Le travail de construction des variables produit souvent plus de gain que le changement d'algorithme. Il est aussi la seule partie du pipeline qu'un agronome peut relire et contester.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

La vérité terrain : ce que le satellite ne donne jamais

Nature, coût et fabrication d'un label agricole.

1 319

points terrain pour cartographier les cultures d'un pays entier

Carte nationale des cultures produite en moins de dix jours et utilisée pour cibler une aide publique. Togo, 2020.

Ordre de grandeur. Plusieurs millions de pixels disponibles, quelques centaines à quelques milliers de labels. Le rapport est de un à mille, et c'est le côté rare qui limite le modèle.

Comment un label est fabriqué

1

Se rendre sur la parcelle

Un agent, un déplacement, un coût unitaire. C'est ce coût qui fixe la taille du jeu de labels.

2

Relever position et date

Sans date, la série temporelle ne peut pas être alignée sur le cycle de la culture.

3

Observer, pas seulement demander

La culture déclarée et la culture observée diffèrent régulièrement. Noter les deux.

4

Mesurer si le rendement est visé

Un carré délimité est récolté et pesé, puis extrapolé. C'est lent, cher, et c'est la seule mesure directe.

PROPAGATION D'UNE ERREUR DE GÉOLOCALISATION

Erreur GPS de 20 m

Grille de 10 m

Décalage de 2 pixels

Label du champ voisin

Appris comme vérité

À RETENIR Sur un projet agricole, la marge de progression est presque toujours du côté des labels, rarement du côté du volume d'images.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION


PRÉDICTION

DÉCISION

Arbre de décision, forêt aléatoire et alternatives


Random Forest sert de référence dans ce cours et dans le TP.

UN ARBRE PROFOND



Découpe les données jusqu'à les mémoriser : c'est le surapprentissage.

UNE FORÊT ALÉATOIRE



Chaque arbre voit un échantillon différent. L'agrégation annule leurs mémorisations.

POURQUOI CE MODÈLE EN TÉLÉDÉTECTION

- 01 Tolère la forte corrélation entre bandes
- 02 Fonctionne avec peu d'observations et beaucoup de variables
- 03 Capture des relations non linéaires
- 04 Fournit une mesure d'importance des variables

XGBoost

Souvent meilleur sur données tabulaires, au prix d'un réglage plus lourd. Mêmes pièges d'évaluation.

Réseaux de neurones convolutifs

Pour les images acquises au champ, par exemple les maladies foliaires. Exigent un grand volume d'images annotées.

Usage dans la littérature

Sur 272 articles de premier quartile publiés entre 2019 et 2023, Random Forest est l'algorithme le plus fréquent en agriculture : 19,2 %, devant SVM à 15,9 %.

À RETENIR La forêt aléatoire corrige le surapprentissage d'un arbre isolé. Elle ne corrige rien du problème de généralisation géographique, qui fait l'objet de la partie suivante.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

Choisir une métrique adaptée

Première question d'évaluation : que mesure-t-on ?

EXERCICE

Dans un paysage sahélien où 5 % de la surface est cultivée, quelle accuracy obtient un modèle qui répond systématiquement « non-culture » ? Répondre avant de passer à la suite.

COMPOSITION DU PAYSAGE**5 %**

de parcelles cultivées

95 %

de non-culture

Réponse : 95 % d'accuracy, et aucune parcelle cultivée correctement identifiée.

Métriques à privilégier**Precision****Proportion d'alertes correctes**

Limite les traitements appliqués à des parcelles saines.

Recall**Proportion de cas réels retrouvés**

Limite les zones en difficulté qui passent inaperçues.

F1**Moyenne harmonique des deux**

Métrique à afficher quand la classe positive est minoritaire.

RMSE / MAE**Amplitude de l'erreur en régression**

Une MAE de 0,3 t/ha est directement interprétable par un producteur.

À RETENIR Choisir la bonne métrique ne suffit pas. Il reste à décider sur quelles données elle est calculée : c'est l'objet des deux slides suivantes.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE


ÉVALUATION

PRÉDICTION

DÉCISION

Pourquoi deux parcelles voisines se ressemblent

Deuxième question d'évaluation : sur quelles données mesure-t-on ?



Ce que les deux parcelles ont en commun

- même type de sol
- même régime de pluie
- même calendrier de semis
- même variété achetée au même marché
- mêmes pratiques de désherbage
- même date de récolte

CONSÉQUENCE POUR L'ÉVALUATION

Si A est dans l'entraînement et B dans le test, le modèle n'a pas besoin de comprendre l'agronomie pour bien répondre sur B. Il lui suffit d'avoir mémorisé A.

Le score obtenu ne mesure alors plus la capacité à généraliser, mais la proximité entre les points de test et les points d'entraînement.

On appelle cela l'autocorrélation spatiale : la valeur d'une observation dépend de sa position, et les positions proches se ressemblent.

CE PROBLÈME N'EST PAS PROPRE À L'AGRICULTURE, MAIS IL Y EST MAXIMAL

Il apparaît partout où la donnée a une position : santé publique, épidémiologie, prix de l'immobilier, hydrologie. En agriculture, il est amplifié parce que les labels sont collectés par campagnes de terrain — donc par grappes géographiques — et parce que les facteurs qui déterminent la culture, le sol et le climat, varient lentement dans l'espace.

À RETENIR Retenir la question, pas le terme : mes données de test sont-elles vraiment différentes de mes données d'entraînement, ou seulement voisines ?

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION


PRÉDICTION

DÉCISION

Random split et spatial split : deux façons de découper les données


Troisième question d'évaluation : comment séparer entraînement et test ?

Random split



Les points de test sont dispersés parmi les points d'entraînement. Chaque point de test a un voisin appris à quelques dizaines de mètres.

Spatial split



Les zones d'entraînement et de test sont disjointes. Le modèle doit répondre sur un territoire dont aucun point n'a été appris.

« Est-ce que je teste ailleurs... ou juste à côté ? »

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

PARTIE 5 • TP GUIDÉ • 30 MIN

Effet du mode de découpage sur la performance mesurée

Cartographie crop / non-crop • forêt aléatoire • random split puis spatial split

Objectif : obtenir un score élevé avec un protocole d'évaluation inadapté, puis mesurer l'écart avec un protocole correct.

Résultats : effet du mode de découpage sur le F1

Mêmes données, mêmes variables, mêmes réglages, même graine aléatoire.

≈ 95 %

F1 en random split

Les points de test sont voisins de points appris.

≈ 65 %

F1 en spatial split

Les points de test sont dans une zone jamais vue.

**-30
points**

écart mesuré

IMPORTANCE DES VARIABLES

Les descripteurs du cycle, comme la date du pic, ressortent devant les bandes brutes. C'est cohérent : ils décrivent la culture, tandis que les bandes brutes décrivent aussi l'endroit.

DEUX CONSÉQUENCES MOINS ÉVIDENTES

L'erreur Out-Of-Bag d'une forêt aléatoire est elle aussi une estimation de type aléatoire : elle est surestimée pour la même raison. Et dans une revue systématique de 272 articles de premier quartile sur le ML agricole, la validation spatiale ne figure pas parmi les défis identifiés.

À RETENIR Le second chiffre décrit la performance attendue sur un territoire nouveau. C'est donc celui à reporter dans un rapport, une publication ou une réponse à appel d'offres.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

Le même raisonnement appliqué au temps

Ce qui vaut pour deux parcelles voisines vaut pour deux dates voisines.

ANNÉE HUMIDE

2022

Année d'entraînement. Les seuils sont calés sur ce cycle.



ANNÉE SÈCHE

2024

Le cycle est décalé de plusieurs semaines. Les seuils ne tiennent plus.

Domain shift

La relation entre X et y a changé.

CAS DOCUMENTÉ — SÉNÉGAL, ARACHIDE ET MILLET

Un modèle prédit le rendement un mois avant la récolte à partir des anomalies de pluie et des séries de végétation. Il fonctionne d'une année sur l'autre, sauf lors des épisodes de sécheresse tardive, où l'erreur augmente nettement — c'est-à-dire précisément dans les situations où une assurance indicielle serait mobilisée.

Leave-one-year-out

Entraîner sur $n - 1$ années et tester sur l'année écartée. C'est l'équivalent temporel du bloc spatial.

Domaine d'applicabilité

Mesurer la distance entre une zone nouvelle et les données d'entraînement, et masquer la carte là où le modèle extrapole.

À RETENIR Un modèle agricole se valide sur un autre lieu et sur une autre année. Les deux protocoles sont indépendants et tous deux nécessaires.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

Trois cas où un modèle performant échoue sur le terrain

Biais de collecte, résolution inadaptée, échantillon non représentatif.

Biais de collecte

CE QUI ÉTAIT OBSERVÉ

Un réseau de neurones atteint une précision proche de 99 % sur une base d'images de feuilles photographiées en laboratoire.

CAUSE

Entraîné sur des recadrages ne contenant aucune feuille, uniquement le fond, il reste très performant. Le modèle utilisait le décor de prise de vue.

Collecter au champ et tester sur des images acquises en conditions réelles.

Résolution inadaptée

CE QUI ÉTAIT OBSERVÉ

Une classification donne de bons résultats sur des exploitations de grande taille.

CAUSE

En dessous d'environ 0,5 ha, un pixel de 10 m couvre à la fois du sol nu, des arbres et de la culture. La signature ne décrit plus une culture unique.

Vérifier l'adéquation entre taille des parcelles et résolution avant de choisir le modèle.

Échantillon non représentatif

CE QUI ÉTAIT OBSERVÉ

Un modèle appris sur une station de recherche obtient d'excellents scores en validation.

CAUSE

La station est désherbée, irriguée et conduite sur une variété unique. La parcelle paysanne est enherbée, pluviale et en cultures associées.

Échantillonner la diversité réelle des pratiques, et non les conditions optimales.

CONTRE-EXEMPLE — DIAGNOSTIC DE MALADIES DU MANIOC, AFRIQUE DE L'EST

Base construite à partir d'images acquises au champ, sur téléphone, dans les conditions réelles de lumière et de propreté d'objectif. Modèle plus léger, base moins homogène, performances conservées en déploiement.

ORIGINE DE LA LITTÉRATURE DU DOMAINE

Sur 272 articles de premier quartile retenus par une revue systématique, la Chine et les États-Unis en signent 126. Aucun pays africain dans les sept premiers.

Dans les trois cas, la métrique était correcte et le modèle correctement entraîné. Le problème portait sur les données.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE


ÉVALUATION

PRÉDICTION

DÉCISION

De la prédiction à la décision agricole

Les conditions d'adoption d'une recommandation par un producteur.



Étape couverte par le cours.

Étape où la chaîne s'interrompt le plus souvent.

FACTEURS QUI DÉTERMINENT L'ADOPTION, EN AVAL DU MODÈLE

Coût du traitement rapporté au revenu de la parcelle • disponibilité effective du produit sur le marché local • confiance accordée à un diagnostic rendu par un téléphone • délai entre l'alerte et l'intervention utile • présence d'un agent de vulgarisation pour accompagner le geste.

Valeur agricole d'un modèle = performance technique × validité sur le terrain visé × capacité d'action

Il s'agit d'un produit : si l'un des trois termes est nul, le résultat l'est aussi.



Six points de contrôle avant de construire un modèle agricole

Check-list applicable à vos propres projets.

01

Partir de la décision agricole

Elle fixe la tâche, la sortie attendue et la métrique à surveiller.

02

Vérifier l'adéquation entre résolution et parcelles

Taille médiane des parcelles de la zone, revisite du capteur, nombre de bandes.

03

Travailler sur le cycle, pas sur une image

Descripteurs du cycle plutôt que valeurs spectrales isolées : date du pic, amplitude, aire sous la courbe.

04

Documenter la vérité terrain

Nombre de labels, mode de collecte, précision de la position, écart entre culture déclarée et observée.

05

Évaluer dans l'espace et dans le temps

Bloc spatial et leave-one-year-out. Ne pas se fier au random split ni à l'erreur Out-Of-Bag.

06

Vérifier la faisabilité de l'action recommandée

Coût, disponibilité, délai, accompagnement. Une recommandation inapplicable n'a pas de valeur agricole.

À RETENIR Sur la plupart des projets agricoles, la marge de progression se situe dans les points 2, 4 et 5 — la donnée, les labels et le protocole d'évaluation — plutôt que dans le choix de l'algorithme.

PROBLÈME

DONNÉES

LABELS

FEATURES

MODÈLE

ÉVALUATION

PRÉDICTION

DÉCISION

UNE QUESTION POUR FINIR

**Votre modèle fonctionnerait-il encore
dans une autre région, une autre année,
et chez un autre agriculteur ?**

Merci